
Регулярные выражения
Начало

Найти все слова, начинающиеся на “при” и заканчивающиеся на “тся” или “ться”

```
1.  def filter_words(words):
2.      results = []
3.      for word in words:
4.          word = word.lower()
5.          if word.startswith('при') and \
6.                  (word.endswith('тся') or word.endswith('ться')):
7.              results.append(word)
8.      return results
```

Найти все слова с приставкой “при” и суффиксами “тся” или “ться”

```
1.  import re
2.
3.  def filter_words_regexp(words):
4.      results = []
5.      pattern = '^при.*ть?ся$'
6.      for word in words:
7.          if re.match(pattern, word, re.IGNORECASE):
8.              results.append(word)
9.      return results
```

Проверить корректность email

kiton1994@gmail.com

- Есть собака @
- Строка перед @ состоит из строчных и заглавных букв латинского алфавита, цифр, символов “_”, “.”, “+”, “-” и не может быть пустой
- Строка после @ (домен) состоит из строчных и заглавных букв латинского алфавита, цифр, символа “-” и не может быть пустой
- После домена идет точка
- После точки идет строка, состоящая из из строчных и заглавных букв латинского алфавита, цифр, символа “-”, которая не может быть пустой

(^[a-zA-Z0-9_.+-]+@[a-zA-Z0-9-]+\.[a-zA-Z0-9-.]+$)

Зачем нужны регулярные выражения?

- Сравнение с шаблоном
- Извлечение шаблонных фрагментов информации
- Замена
- Портируемость
- Быстро и лаконично

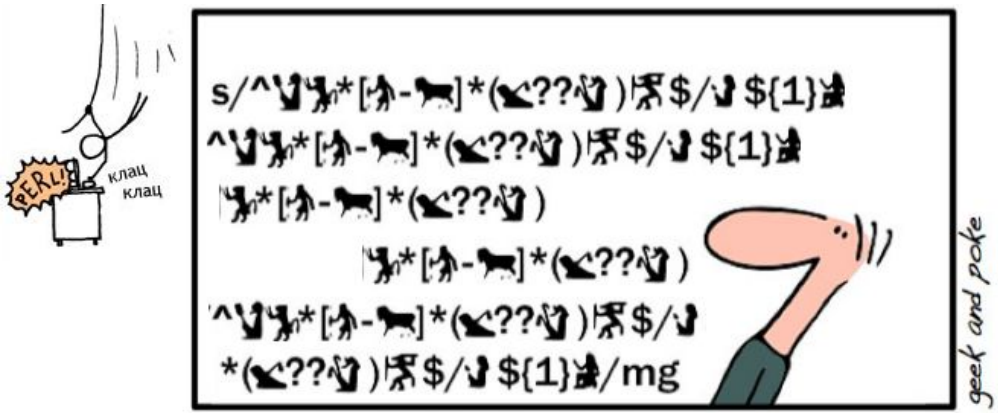

Если можно не пользоваться регулярками -
не пользуйтесь ими!

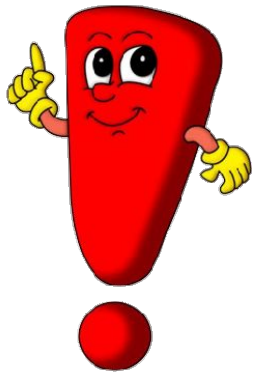

Как использовать регулярки

```
>>> import re
>>> text = 'Кот пришёл к коту и спросил кота: «Бойкот, котелок или скотч?»'
>>> pattern = 'кот.'
>>> result = re.search(pattern, text)
>>> print(result)
>>> print(result.group())
<_sre.SRE_Match object; span=(13, 17), match='коту'>
коту
```

Как использовать регулярки

re.search(pattern, string) - возвращает первое вхождение подстроки, которая подходит под регулярное выражение

re.findall(pattern, string) - возвращает все вхождения подходящих строк

re.match(pattern, string)* - возвращает True, если строка совпадает с шаблоном и False, если не совпадает

Язык регулярок

Точка “.”

Один любой символ

```
>>> text = 'кот! коты коту котами'
>>> pattern = 'кот.'
>>> result = re.search(pattern, text)
>>> print(result.group())
кот!
```

Вопросительный знак “?”

Ноль или ровно одно вхождение **предыдущего** символа

```
>>> text = 'кот! коты коту котами'
>>> pattern = 'кот.?'
>>> result = re.findall(pattern, text)
>>> print(result)
```

```
['кот!', 'коты', 'коту', 'кота']
```

Звездочка “*”

Ноль или сколько угодно вхождений **предыдущего** символа (>= 0)

```
>>> text = 'abb abba abbbbba aaaab'
>>> pattern = 'ab*a'
>>> result = re.findall(pattern, text)
>>> print(result)
```

```
['abba', 'abbbbba', 'aa', 'aa']
```

Плюс “+”

Одно или сколько угодно вхождений **предыдущего** символа (> 0)

```
>>> text = 'aaaaa abba abaa'
>>> pattern = 'ab+a'
>>> result = re.findall(pattern, text)
>>> print(result)
```

```
['abba', 'aba']
```

Крышка “^”

Начало строки. То есть строка должна начинаться с шаблона

```
>>> import re
>>> words = ['кот', 'мрот', 'скот', 'крот']
>>> pattern = '^к.+от'
>>> for word in words:
...     if re.match(pattern, word):
...         print(word)
```

крот

Доллар “$”

Конец строки. То есть строка должна оканчиваться шаблоном

```
>>> import re
>>> words = ['коты', 'мрот', 'от', 'скот', 'кота', 'живот']
>>> pattern = '.+от$'
>>> for word in words:
...     if re.match(pattern, word):
...         print(word)
мрот
скот
живот
```

В квадратной скобке “[abc]”

Здесь должно быть что-то из символов в скобках: “a” или “b” или “c”

```
>>> import re
>>> text = 'кот мрот скот крот'
>>> pattern = '[кмр]от'
>>> result = re.findall(pattern, text)
>>> print(result)
['кот', 'рот', 'кот', 'рот']
```

Диапазон в квадратных скобках “[а-я0-9]”

Внутри скобок можно указывать диапазоны:

- а-я - все строчные буквы русского алфавита
- A-Z - все заглавные буквы английского алфавита
- 0-9 - все цифры

Внутри квадратных скобок большинство специальных символ не действуют: . обозначает точку, ? — вопросительный знак. Вне квадратных скобок, чтобы получить точку или, например, плюс, специальные символы надо экранировать с помощью \ (\. обозначает точку, \+ обозначает плюс).

Диапазон в квадратных скобках “[а-я0-9]”

```
>>> import re
>>> text = 'Я-родился-30февраля-1930года-в-15:45'
>>> pattern = '[А-Я0-9]+'
>>> result = re.findall(pattern, text)
>>> print(result)
['Я', '30', '1930', '15', '45']
```

Крышка внутри квадратных скобок “[^abc]”

Все, кроме любого из символов в скобках

```
>>> import re
>>> text = 'кот мрот скот крот'
>>> pattern = '[^мр]от'
>>> result = re.findall(pattern, text)
>>> print(result)
```

```
['кот', 'кот']
```

Помощник “\d”. Настоящее название - **символьный класс**

Любая цифра, аналогично [0-9]

```
>>> import re
>>> text = 'Я-родился-30февраля-1930года-в-15:45'
>>> pattern = '[^а-я]\d'
>>> result = re.findall(pattern, text)
>>> print(result)
```

```
['-3', '-1', '93', '-1', ':4']
```

Помощник “\D”

Любой символ, кроме цифр (эквивалентно [^0-9])

```
>>> import re
>>> text = 'Яродился30февраля1930года'
>>> pattern = '\D+'
>>> result = re.findall(pattern, text)
>>> print(result)
['Яродился', 'февраля', 'года']
```

Помощник “\w”

Буквы, цифры, “_”

```
>>> import re
>>> text = '«Бойкот, котелок или скотч?» 18 февраля __main__'
>>> pattern = '\w+'
>>> result = re.findall(pattern, text)
>>> print(result)

['Бойкот', 'котелок', 'или', 'скотч', '18', 'февраля', '__main__']
```

Помощник “\W”

Все, кроме букв, цифр и знака “_”

```
>>> import re
>>> text = 'иван, петр, маша!надо.было.быть'
>>> pattern = '\W+'
>>> result = re.findall(pattern, text)
>>> print(result.count(','))
0
```

Помощники “\s” и “\S”

Все пробелоподобные символы, аналогично [\t\n\r]. Любой непробелоподобный символ

```
>>> import re
>>> text = '''Кот пришёл к коту и спросил кота:
... «Бойкот, котелок или скотч?»'''
>>> pattern = '\S+'
>>> result = re.findall(pattern, text)
>>> print(result)
```

```
['Кот', 'пришёл', 'к', 'коту', 'и', 'спросил', 'кота:', '«Бойкот,', 'котелок', 'или', 'скотч?»']
```

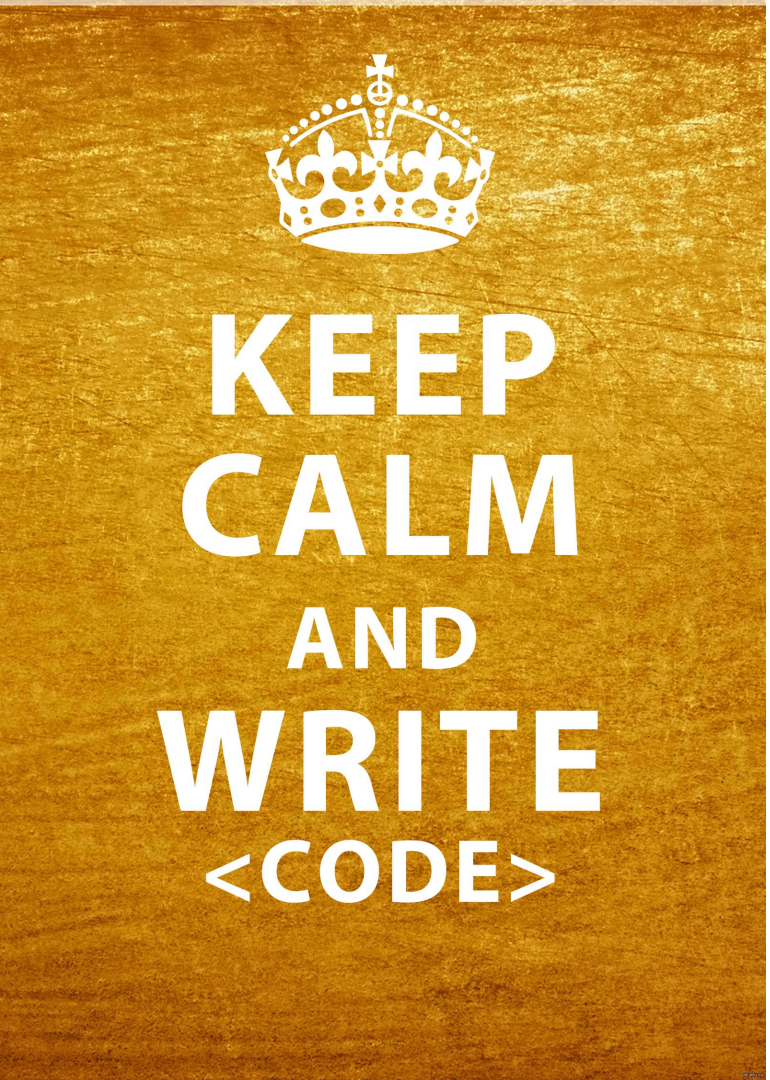

http://
SEMiCODE.ru
/tasks/14